实验方案

看看这段聊天

有人觉得你可能会想看看这段聊天。

https://chatgpt.com/s/t_6abd2ace7b208191b75778d67f7ad26d

可以。这个 idea 的实验不能只做“Adaptive EGNN 比 fixed-depth 好一点”，而要把整篇文章的证据链做成：

不同样本最优深度不同
→ 深度差异与结构/性质复杂度有关
→ adaptive halting 能学到它
→ 减少 oversmoothing + 节省计算

而且要专门对付 ICML 2025 的 **Adaptive Message Passing**：它已经提出 adaptive depth 来缓解 oversmoothing、oversquashing、underreaching，所以我们的重点必须是 **3D equivariant + structure/property-dependent computation + symmetry-preserving halting**。Proceedings of Machine Learning Research

---

一、论文最终要回答 6 个问题

我会直接把实验章节按照下面 6 个 RQ 来设计：

RQ	核心问题	最关键证据
RQ1	不同 molecule/crystal 是否真的需要不同 depth？	per-sample optimal-depth distribution
RQ2	不同 property 是否需要不同 depth？	同一 molecule，不同 property 的 optimal depth
RQ3	Adaptive Loop 是否能自动找到合适 depth？	learned depth vs oracle depth
RQ4	是否真的缓解 oversmoothing / underreaching？	feature similarity + error-depth curves
RQ5	是否真的节省计算？	MAE–FLOPs / MAE–latency Pareto
RQ6	adaptive computation 是否保持 $E(3)$ symmetry？	rotation/translation 后 prediction 和 halt depth 不变

其中 **RQ1+RQ2 是这篇文章能不能成立的命门**。

如果它们不成立，后面 adaptive computation 再漂亮都只是 architecture trick。

二、我建议的数据集组合

不要只做 QM9。

QM9 约 134k 分子，但最多只有 9 个重原子，结构复杂度跨度其实不够大。Nature

所以我建议：

Dataset	目的	为什么需要
QM9	property-conditioned depth	同一分子有很多性质
QMugs	structure-conditioned depth	平均约 30.6、最大 100 heavy atoms
Matbench	crystal generalization	证明不是 molecule-only trick

QMugs 有超过 665k 个药物样分子、约 2M conformers，而且分子显著大于 QM9，非常适合你这个故事。Nature

---

三、Experiment 0：先别训练 adaptive model，先验证故事

这是我最建议你**第一个做**的实验。

3.1 Fixed-depth sweep

先训练普通 EGNN：

$$L \in \{1, 2, 3, 4, 6, 8, 10, 12\}.$$

但是这里要做两组。

A. 普通 untied EGNN

$$F_{\theta_1} \to F_{\theta_2} \to \cdots F_{\theta_L}$$

用于回答：

> 正常模型的 optimal depth 是否随结构变化？

B. Weight-tied Loop EGNN

$$F_\theta^1 \to F_\theta^2 \to \cdots F_\theta^{12}.$$

用于回答：

> 同一个 iterative operator 多执行几轮是否也存在不同最佳 stopping point？

第二个其实更重要，因为它跟后面的 adaptive loop 完全一致。

四、先定义一个非常重要的量：Oracle Depth

对于每个样本 i ，每一层都有预测：

$$\hat{y}_i^{(1)}, \hat{y}_i^{(2)}, \ldots, \hat{y}_i^{(K_{\max})}.$$

定义：

$$e_i(k) = \ell(\hat{y}_i^{(k)}, y_i).$$

最简单的 oracle：

$$K_i^\star = \arg\min_k e_i(k).$$

但我更推荐加入计算成本：

$$\boxed{K_i^\star = \arg\min_k \left[e_i(k) + \lambda_{\text{oracle}} \frac{k}{K_{\max}} \right]}$$

这叫：

Minimum Sufficient Depth

不是问：

> 跑多少层误差绝对最小？

而是：

> **至少需要思考多少层，才能得到足够好的答案？**

更符合你的 paper story。

这个 oracle 只用于分析，不能用于 inference。

五、RQ1：真的存在 sample-dependent depth 吗？

先画最关键的一张图。

横轴：

$$K = 1, \ldots, 12$$

纵轴：

$$\text{MAE}(K)$$

但不要只画 dataset average。

把 molecule 按 complexity 分组。

分子 complexity

对每个 molecule 计算：

$$C(G) = \{N_{\text{atom}}, D_{\text{graph}}, R_g, N_{\text{ring}}, N_{\text{rotatable}}, H_{\text{element}}, \bar{d}, \ldots\}.$$

最重要的建议保留：

指标	含义
N_{atom}	atom count
指标	含义
D_{graph}	molecular graph diameter
R_g	radius of gyration
ring count	环复杂度
rotatable bonds	柔性
element diversity	化学组成复杂度

不要人为把这些塞给 halting model。

只用于 post-hoc analysis。

然后按照例如 D_{graph} 分成：

$$Q_1, Q_2, Q_3, Q_4$$

四组。

最后希望看到：

$$K^\star(Q_1) < K^\star(Q_2) < K^\star(Q_3) < K^\star(Q_4).$$

例如最后可能出现：

Complexity quartile	Optimal depth
Q1	2.8
Q2	3.7
Q3	5.1
Q4	6.6

这个结果如果出来，paper 基本就立住一半了。

六、再做一张非常重要的 individual curve

不要只报 average。

找三种 molecule：

Easy

$$e_i(1) > e_i(2) > e_i(3)$$

之后：

$$e_i(4) < e_i(5) < e_i(6) \dots$$

开始恶化。

即：

$$K_i^\star = 3.$$

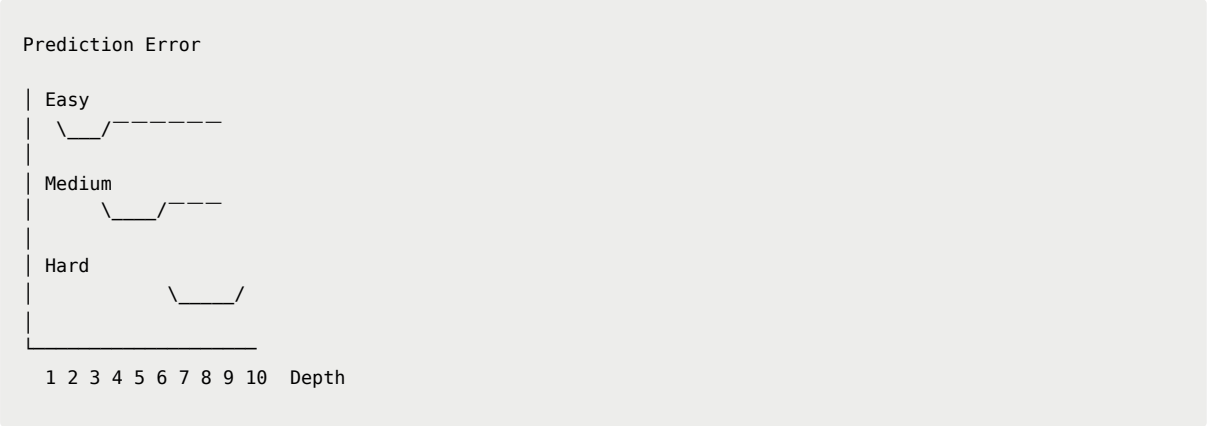
Medium

$$K_i^\star = 6.$$

Hard

$$K_i^\star = 10.$$

画成：



这图特别适合 Introduction teaser。

一句话：

> There is no universally optimal message-passing depth.

七、RQ2：同一个 molecule，不同 property 是否需要不同 depth？

这是 **QM9 最重要的实验**。

QM9 本身覆盖 dipole、polarizability、orbital energies、thermodynamic quantities 等多种 quantum property。Nature

先选四个代表性 target：

$$\mu, \quad \alpha, \quad \text{HOMO/LUMO gap}, \quad U_0.$$

后面完整版再跑全部 QM9 properties。

Property-conditioned halting

对于同一个 molecule：

$$G_i$$

不要定义：

$$K_i = f(G_i)$$

而是：

$$\boxed{K_{i,p} = f(G_i, p)}$$

其中：

$$p = \text{target property}.$$

于是同一个结构可能：

$$K_{i,\mu} = 3$$

但是：

$$K_{i,\text{gap}} = 7.$$

最漂亮的图

做一个 heatmap：

纵轴：

$$\mu, \alpha, \epsilon_{\text{HOMO}}, \epsilon_{\text{LUMO}}, \Delta\epsilon, U_0, C_v, \ldots$$

横轴：

molecule complexity quartile。

颜色：

$$\mathbb{E}[K].$$

最终如果出现：

```
                structural complexity
             Q1    Q2    Q3    Q4

Dipole       2.7   3.1   3.8   4.4
Alpha        3.0   3.9   5.0   6.2
```

```
HOMO        3.4   4.4   5.8   7.1
Gap         3.8   4.8   6.2   7.8
U0          2.5   3.0   3.8   4.6
```

那就非常漂亮。

核心 conclusion：

$$\boxed{\text{Required depth depends on both structure and property.}}$$

八、主模型具体怎么写

我建议名字暂时：

$$\boxed{\text{AdaLoop-EGNN}}$$

初始化：

$$(h^{(0)}, x^{(0)}) = \text{Embed}(G).$$

一个共享 EGNN operator：

$$(h^{(k+1)}, x^{(k+1)}) = F_\theta(h^{(k)}, x^{(k)}, E).$$

其中：

$$\theta^{(1)} = \theta^{(2)} = \cdots = \theta^{(K_{\max})}.$$

建议第一版：

$$K_{\max} = 12.$$

hidden dimension：

$$d = 128.$$

32 个 radial basis functions。

molecule cutoff：

$$r_c = 5\text{Å}.$$

先不要疯狂调超参。

九、每一层都能预测

每一步：

$$z^{(k)} = \text{Pool}(h^{(k)}).$$

然后：

$$\hat{y}^{(k)} = R_\psi(z^{(k)}, e_p)$$

其中 e_p 是 property embedding。

这样你直接得到：

$$\hat{y}^1, \hat{y}^2, \ldots, \hat{y}^{12}.$$

这是整个 adaptive mechanism 的基础。

十、Halting Controller

这是核心。

不要直接输入坐标。

构造：

$$s_k = [\mathrm{MeanPool}(h^k), \mathrm{StdPool}(h^k), \Delta_k, e_p].$$

其中：

$$\Delta_k = \frac{1}{N}\sum_i \|h_i^k - h_i^{k-1}\|_2.$$

它表示：

> representation 还在发生多大变化？

然后：

$$q_k = \sigma(\mathrm{MLP}_{halt}(s_k)).$$

解释：

$$q_k = P(\text{stop at } k \mid \text{not stopped before}).$$

因此：

$$p_k = q_k \prod_{j<k}(1 - q_j).$$

并强制：

$$q_{K_{\max}} = 1.$$

十一、训练 Loss 我建议这样

目标全部 standardize：

$$\tilde{y} = \frac{y - \mu_y}{\sigma_y}.$$

Prediction loss：

$$\mathcal{L}_{\text{pred}} = \sum_{k=1}^{K_{\max}} p_k \ell(\hat{y}^{(k)}, y).$$

再加 computation cost：

$$\mathcal{L}_{\text{compute}} = \sum_k p_k \frac{k}{K_{\max}}.$$

最终：

$$\boxed{\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda_c \mathcal{L}_{\text{compute}}}$$

这特别漂亮：

模型会自己学：

$$\text{prediction quality} \quad \text{vs} \quad \text{computation}.$$

建议 sweep：

$$\lambda_c \in \{0,\ 0.01,\ 0.03,\ 0.1\}.$$

这样天然得到一条：

$$\boxed{\text{accuracy-compute Pareto frontier}}$$

而不是只挑一个 λ。

十二、训练上我建议加一个 warm-up

否则 controller 很容易一开始全停在：

$$K = 1$$

或者全部跑：

$$K = 12.$$

所以训练分两阶段。

前 20% epoch：

随机 sample depth：

$$K \sim U(1, K_{\max})$$

然后只训练：

$$\mathcal{L} = \ell(\hat{y}^{(K)}, y).$$

让所有深度先具备预测能力。

后 80%：

打开：

$$\mathcal{L}_{\text{pred}} + \lambda_c \mathcal{L}_{\text{compute}}.$$

这个实现上会稳定很多。

十三、QM9 具体实验

建议沿用常见的过滤与 split：

约 130,831 structures：

$$110k \text{ train}, 10k \text{ validation}, \text{remaining test}.$$

这也是已有 equivariant molecular work 使用的设置。Nature

先跑四个 property：

$$\mu, \alpha, \Delta\epsilon, U_0.$$

跑通以后再扩所有 target。

十四、但是结构复杂度主实验放 QMugs

这个非常重要。

QMugs 平均约：

$$30.6$$

heavy atoms，最大：

$$100.$$

比 QM9 好太多。Nature

我第一版甚至不用整个 665k。

抽：

$$200k$$

molecules。

按照 heavy atom count 分层抽：

$$10-20,\quad 21-40,\quad 41-60,\quad >60.$$

每档保证足够数量。

QMugs target

非常适合选：

$$E_{\mathrm{form}}$$

$$\mu$$

$$E_{\mathrm{HOMO}}$$

$$E_{\mathrm{LUMO}}$$

$$E_{\mathrm{gap}}.$$

这些都在 QMugs 中提供。Nature

这样：

QM9：

> property dependency

QMugs：

> structural complexity dependency

故事特别完整。

十五、强烈建议再做一个 controlled synthetic experiment

这个实验不是为了 benchmark。

而是为了证明：

$$\boxed{\text{required interaction range} \Rightarrow \text{required computation depth}}$$

否则“复杂 molecule 要更深”始终只是 correlation。

构造 Long-Range Molecular Task

直接使用真实 molecular geometry。

定义：

$$y_R = \sum_{i,j:d_G(i,j)\geq R} w(Z_i,Z_j)\exp(-\gamma r_{ij}).$$

分别构造：

$$R = 1, 2, 3, 4, 5.$$

随着 R 增大，任务需要越来越远的信息。

理论预期：

$$\boxed{R \uparrow \Rightarrow K_{\text{halt}} \uparrow}$$

画：

$$R \quad \text{vs} \quad E[K].$$

如果是接近单调关系，那会非常有说服力。

这个实验可以直接把：

> adaptive depth represents information propagation demand

讲清楚。

十六、RQ4：Oversmoothing 一定要实测

不要只说 adaptive depth “可以避免 oversmoothing”。

必须测。

第一种指标：

$$S_k = \frac{1}{N(N-1)} \sum_{i \neq j} \cos(h_i^k, h_j^k).$$

如果：

$$S_k \to 1$$

说明 node representations 越来越相似。

第二个我更推荐：

Dirichlet Energy

$$\mathcal{E}^{(k)} = \frac{1}{|E|} \sum_{(i,j) \in E} \|h_i^k - h_j^k\|_2^2.$$

oversmoothing 时：

$$\mathcal{E}^{(k)} \to 0.$$

然后同时画：

$$\text{Prediction MAE}(k)$$

和：

$$\mathcal{E}^{(k)}.$$

希望看到：

```
depth ↑

Dirichlet energy  ↓↓↓↓↓
Prediction error  ↓↓↓ ↑↑
                      ↑
                oversmoothing
```

而 AdaLoop：

$$\boxed{\text{halts before representation collapse}}$$

这个故事非常完整。

十七、还要专门测 underreaching

把 test molecules 按 graph diameter 分组：

$$D_G = 1{-}3,\ 4{-}5,\ 6{-}7,\ 8+.$$

然后比较：

Fixed-2：

大 diameter 上 error 很高。

Fixed-4：

改善。

Fixed-8：

复杂结构好，但简单结构开始过深。

Adaptive：

小图：

$$K \approx 2-3$$

大图：

$$K \approx 6-9.$$

这会直接对应：

$$\boxed{\text{underreaching} \leftrightarrow \text{oversmoothing}}$$

之间的矛盾。

这也是 AMP 2025 明确讨论的三个核心问题，因此这组实验有利于正面对比最近工作。Proceedings of Machine Learning Research

---

十八、Baseline 我会这样安排

这是主表必须有的：

Model	Weight sharing	Adaptive depth	Equivariant
EGNN-2	No	No	✓
EGNN-4	No	No	✓
EGNN-6	No	No	✓
EGNN-8	No	No	✓
EGNN-12	No	No	✓
Loop-EGNN-4	Yes	No	✓
Loop-EGNN-8	Yes	No	✓
Loop-EGNN-12	Yes	No	✓
Random Depth	Yes	Random	✓
Size-based Depth	Yes	heuristic	✓
AMP-style baseline	adaptive	✓	depends
AdaLoop-EGNN	**Yes**	**Yes**	**✓**
Oracle Depth	Yes	Oracle	✓

特别重要的是：

Size-based heuristic

例如：

$$K = \mathrm{clip}\left(\lceil N_{\mathrm{atom}}/10 \rceil, 1, K_{\max}\right).$$

因为 reviewer 很可能问：

> 你搞一个神经 controller 有什么用？按分子大小决定不就行了？

必须主动堵住这个问题。

十九、还必须做一个 budget-matched baseline

假设你的模型：

$$E[K] = 4.7.$$

那么不能只拿它和 Fixed-12 比。

必须比较：

$$\text{Fixed-}5.$$

即：

$$\boxed{\text{same average compute budget}}$$

如果：

$$\text{MAE}_{Adaptive} < \text{MAE}_{Fixed-5}$$

才能说明：

> gain 来自 **allocate computation differently across examples**，

而不是单纯算得更多。

这个 baseline 极其重要。

二十、效率实验怎么报

不要只报 params。

因为 weight tying 会让 parameter 很漂亮，但真实计算量还是取决于 loops。

至少报：

$$\text{Params}$$

$$\text{Average steps}$$

$$\text{FLOPs/sample}$$

$$\text{GPU latency}$$

$$\text{peak memory.}$$

最重要的是做：

Accuracy–Compute Curve

横轴：

$$\text{Average FLOPs}$$

纵轴：

$$\text{MAE.}$$

Fixed models：

一堆点。

Adaptive model：

改变 λ_c ：

$$0, 0.01, 0.03, 0.1$$

得到一条曲线。

如果你的曲线整体位于 fixed-depth 左下方：

$$\boxed{\text{Pareto improvement}}$$

这个结果非常强。

二十一、Symmetry experiment

这个实验很便宜，但必须做。

随机取：

$$1000$$

test structures。

对每个 structure 产生：

$$x_i' = Rx_i + t.$$

包括：

rotation；

translation；

reflection。

然后比较：

Prediction

对于 scalar property：

$$|\hat{y}(G) - \hat{y}(gG)|.$$

应该：

$$< 10^{-5}$$

或者 numerical precision 附近。

更重要的是：

Halting depth

检查：

$$\boxed{K(G) = K(gG)}$$

报告：

$$\text{Halting Consistency} = \frac{1}{N}\sum_i \mathbf{1}[K(G_i) = K(gG_i)].$$

目标：

$$100\%.$$

这就是你区别普通 early-exit GNN 的一个漂亮点：

> **not only predictions, but computation paths respect Euclidean symmetry.**

二十二、Crystal 实验不要直接硬改 EGNN

这一点我会比较谨慎。

原始 EGNN 本身就是针对 rotation、translation、reflection 和 permutation equivariance 构造的。Proceedings of Machine Learning Research

但 periodic crystal 上直接 recurrently 更新 Cartesian coordinates，会引入 PBC 处理和 latent-coordinate drift 等额外问题。

所以 paper 最干净的做法是：

Molecule

$$\text{EGNN} \rightarrow \text{AdaLoop-EGNN}.$$

Crystal

换成已有 E(3)-equivariant message passing backbone，比如 PaiNN：

$$\text{PaiNN} \rightarrow \text{AdaLoop-PaiNN}.$$

PaiNN 本身使用 rotationally equivariant representations。Proceedings of Machine Learning Research

这样反而能证明：

$$\boxed{\text{Adaptive Equivariant Computation is backbone-agnostic.}}$$

而不只是：

> 我对 EGNN 做了一个特殊 modification。

二十三、Matbench 具体做哪几个

先做五个：

Task	Samples	Target
phonons	1,265	phonon peak

dielectric	4,764	refractive index
log_gvrh	10,987	shear modulus
perovskites	18,928	formation energy
mp_e_form	132,752	formation energy

这些规模是 Matbench 官方给出的。黑客材料研究组

从小数据到大数据全覆盖。

正式 paper 使用 Matbench 官方 5-fold protocol，而不是自己随机切。官方要求 regression 使用 5-fold KFold、shuffle，并使用固定 seed 18012019。黑客材料研究组

二十四、Crystal complexity 指标

这里分析：

$$N_{\text{cell}}$$

atoms per primitive cell；

$$N_{\text{species}}$$

element diversity；

coordination number variance；

local environment entropy；

volume/atom；

density；

晶体 symmetry；

以及 neighbor graph statistics。

然后：

$$\text{Spearman}(C(G), K_{\text{halt}})$$

做 correlation。

但我不建议宣传：

> 大 crystal 一定需要更多 depth。

更谨慎地说：

> learned computation depth reflects structural interaction complexity.

因为 size 只是 complexity 的一个 proxy。

二十五、最关键的 Ablation

最后至少需要这张表：

Variant	MAE	Avg. K	FLOPs
Fixed depth			
+ Weight sharing			
+ Adaptive halt			
– computation penalty			
– property conditioning			
– representation residual Δ_k			
Size-based halt			
Random halt			
Full	**	**	**

这里最重要的两个：

去掉 property conditioning

$$q_k = f(z_k)$$

vs.

$$q_k = f(z_k, e_p).$$

证明：

$$\boxed{\text{property matters}}$$

去掉 compute penalty

$$\lambda_c = 0.$$

大概率会：

$$K \to K_{\max}.$$

这很好。

正好说明 accuracy alone 不会自动产生 adaptive computation。

二十六、Adaptive depth 学得对不对怎么评价

不仅看 accuracy。

拿 oracle：

$$K_i^\star.$$

和 learned：

$$\hat{K}_i.$$

报告：

$$\mathrm{Spearman}(K^\star, \hat{K})$$

以及：

$$\mathrm{MAE}_K = \frac{1}{N}\sum_i |\hat{K}_i - K_i^\star|.$$

还可以：

$$P(|\hat{K} - K^\star| \le 1).$$

于是可以真正说：

> adaptive controller learns to approximate minimum sufficient depth.

而不是只看最终 MAE。

二十七、OOD 实验也很适合这个故事

做一个 molecule-size OOD：

训练：

$$N_{\mathrm{heavy}} \le 40.$$

测试：

$$N_{\mathrm{heavy}} > 40.$$

比较：

Fixed-depth 和 adaptive。

我们希望 adaptive 在大结构上：

$$K_{\mathrm{test}} > K_{\mathrm{train}}.$$

特别有意思的是：

Test-time compute scaling

训练时：

$$K_{\max}^{train} = 8.$$

测试时允许：

$$K_{\max}^{test} = 12,\ 16.$$

看看 complex OOD molecules 会不会继续调用更多 loops。

如果：

$$\mathrm{MAE}_{16} < \mathrm{MAE}_{8}$$

那就非常漂亮：

$$\boxed{\text{the learned operator can think longer at test time}}$$

这会把普通 adaptive-depth paper 往 **iterative reasoning** 再推一步。

但这个可以作为后期加分项，不要第一周就做。

二十八、我建议整篇论文最后只有 4 张核心主图

Figure 1 — Motivation + Method

左边：

```
Simple molecule
○─○─○
  ↓
Loop 1 → Loop 2 → STOP
```

中间：

```
Complex molecule
○─○─○─○─○─○
  ↓
Loop1 → Loop2 → ... → Loop7 → STOP
```

右边：

Adaptive Equivariant Computation。

Figure 2 — Evidence that optimal depth varies

(a)

different complexity → different optimal K

(b)

different properties → different optimal K

(c)

oracle-depth distribution.

这张图实际上是整篇最重要的。

Figure 3 — Adaptive computation

(a)

learned depth vs oracle depth

(b)

depth vs structural complexity

(c)

property × complexity heatmap

(d)

halting distribution.

Figure 4 — Why it works

(a)

MAE vs FLOPs

(b)

oversmoothing Dirichlet energy

(c)

MAE vs depth

(d)

symmetry-consistent halting.

二十九、主结果表应该长这样

Model	QM9 MAE ↓	QMugs MAE ↓	Avg Steps ↓	FLOPs ↓	Params ↓
EGNN-4			4		
EGNN-8			8		
EGNN-12			12		
LoopEGNN-4			4		
LoopEGNN-8			8		
LoopEGNN-12			12		
Budget-matched Fixed			4.8		
Size-based					
AdaLoop-EGNN	**	**	**4.8**	**	**
Oracle					

这里 **Oracle 不要加粗，也不要拿它当 baseline 赢输**。

它只是 upper bound。

三十、我实际会按照这个顺序做

这是唯一真正需要严格按顺序执行的部分：

1. **只用 QM9，先写一个 weight-tied EGNN，** $K_{\max} = 12$ ，所有 layer 共用 prediction head，画每个样本的 error-vs-depth。
2. 算出 $K_i^\star$ ，检查 oracle depth 是否有明显分布，而不是全部集中在某个固定 K 。
3. 检查 $K_i^\star$ 与 atom count、graph diameter、radius of gyration 的关系。
4. 分别看 $\mu, \alpha, \mathrm{gap}, U_0$ ，确认 property-dependent depth 是否存在。
5. **只有前四步成立，再实现 halting controller。**
6. 加 $\mathcal{L}_{\mathrm{compute}}$ ，画 MAE–average-depth 曲线。
7. 加 fixed-budget、random-depth、size-based baseline。
8. 做 oversmoothing、halting symmetry。
9. 上 QMugs，把结构跨度扩大到最高 100 heavy atoms。QMugs 的规模和结构范围正适合验证这个 hypothesis。Nature
10. 最后再把 adaptive loop 接到 PaiNN 上跑 Matbench，作为 crystal + backbone generalization。

最关键的是第一轮不要做太大

我会先只跑一个**杀手级诊断实验**：

$$\boxed{\mathrm{QM9} + \text{Loop-EGNN} + K = 1 \dots 12 + 4 \text{ properties}}$$

然后得到三个量：

$$K_i^\star, \qquad D_{\mathrm{graph}}(G_i), \qquad p_i.$$

接着回答两个问题：

$$\boxed{P(K^\star \mid \text{structure complexity})}$$

和

$$\boxed{P(K^\star \mid \text{property})}$$

如果这两个分布真的明显不同，这篇就值得全力做。

因为此时你的核心发现就已经不是“我发明了 adaptive EGNN”，而是一个更基础的 observation：

> **Equivariant molecular models do not have a universally optimal depth; the minimum sufficient depth varies jointly with molecular structure and predicted property.**

然后 AdaLoop-EGNN 就变成这个 observation 的自然解决方案，而不是为了加模块而加模块。这会让 paper 的逻辑高级很多。